

Radyomik Özellikler Kullanılarak Papilodem Sınıflandırması

1. Giriş

Bu çalışmanın amacı, radyomik özellikler kullanılarak Normal ve Papilodem sınıflarının makine öğrenmesi yöntemleri ile ayrılmasıdır. Problem ikili sınıflandırma problemidir.

2. Veri Seti

Veri seti iki CSV dosyasından oluşmaktadır:

- normal_radiomics.csv
- papilodem_radiomics.csv

Her örnekte 746 radyomik özellik bulunmaktadır.

Hasta bazlı veri bölme kullanılmıřtır; böylece aynı hastaya ait örneklerin farklı train, validation veya test setlerine düşmesi engellenmiştir.

Çalışmada toplam 966 örnekten oluşan bir radyomik veri seti kullanılmıştır. Veri setinde 69 hasta bulunmaktadır. Normal sınıfında 672 örnek ve 48 hasta, papilodem sınıfında ise 294 örnek ve 21 hasta yer almaktadır. Her örnek için 746 radyomik özellik bulunmaktadır. Veri setinde eksik değer ve tekrarlı satır bulunmamaktadır.

Veri seti hasta seviyesinde train, validation ve test alt kümelerine ayrılmıştır. Eğitim setinde 574 örnek ve 41 hasta, validation setinde 196 örnek ve 14 hasta, test setinde ise 196 örnek ve 14 hasta bulunmaktadır. Bu ayırmada aynı hastaya ait örneklerin farklı alt kümelere düşmemesine dikkat edilmiştir.

3. Metodoloji

Çalışmada şu pipeline uygulanmıştır:

1. Veri setlerinin birleştirilmesi.
2. Sınıf etiketlerinin oluşturulması.
3. Hasta seviyesinde train / validation / test ayrımı.
4. Median imputation.
5. Low-variance filtering.
6. Pearson correlation > 0.95 olan özelliklerin elenmesi.
7. RobustScaler ile ölçekleme.
8. MRMR özellik seçimi.
9. Optuna TPE sampler ile hiperparametre optimizasyonu.
10. Model eğitimi.
11. Sigmoid calibration.
12. RF, ET ve GB ile soft voting ensemble.

Bu çalışmada veri sızıntısını önlemek amacıyla tüm ön işleme ve özellik seçimi adımları makine öğrenmesi pipeline'ı içerisinde uygulanmıştır. Median imputation, düşük varyanslı özelliklerin

elenmesi, korelasyon temelli özellik azaltma, RobustScaler ile ölçekleme ve MRMR özellik seçimi eğitim verisi üzerinde fit edilmiştir. Test verisi yalnızca final değerlendirme aşamasında kullanılmıştır.

Model seçimi ve hiperparametre optimizasyonu için StratifiedGroupKFold yapısı kullanılmıştır. Böylece sınıf dağılımı korunurken aynı hastaya ait örneklerin farklı foldlara düşmesi engellenmiştir. Optuna TPE sampler ile her model için 50 trial gerçekleştirilmiş ve amaç fonksiyonu Macro-F1 olarak belirlenmiştir.

Kod parçaları ve açıklamaları aşağıdaki tabloda verilmiştir. Bu bölümde Command+F ile aranabilecek ilgili fonksiyon adları, kısa kod parçaları ve her kodun projedeki görevi birlikte sunulmuştur.

Tablo 1. Kod parçaları ve açıklamaları

İlgili kod parçası	Bu kod ne ise yapıyor?
<pre>load_dataset(raw_dir) normal_raw = pd.read_csv(normal_path) pap_raw = pd.read_csv(pap_path) data = pd.concat([normal, pap], ignore_index=True)</pre>	Normal ve papilodem CSV dosyalarını okur, Target = 0/1 sınıf etiketlerini ekler ve iki veri setini tek tabloda birleştirir.
<pre>make_patient_level_splits(data) outer = StratifiedGroupKFold(...) train_val_idx, test_idx = next(outer.split(data, y, groups))</pre>	Aynı hastaya ait örneklerin farklı train, validation veya test alt kumelerine düşmesini engellemek için hasta seviyesinde veri bölme yapar.
<pre>make_preprocessor(correlation_threshold) ("imputer", SimpleImputer(strategy="median")) ("variance", VarianceThreshold(threshold=0.0)) ("correlation", CorrelationFilter(threshold=correlation_threshold)) ("scaler", RobustScaler())</pre>	Eksik değerleri median ile doldurur, düşük varyanslı ve yüksek korelasyonlu özellikleri eler, ardından RobustScaler ile ölçekleme yapar.
<pre>MRMRSelector.fit(X, y) relevance = mutual_info_classif(X, y, ...) score = float(relevance[idx]) - redundancy</pre>	Mutual information ile sınıfla ilişkili özellikleri bulur, Pearson korelasyonuna dayalı redundancy cezasıyla tekrar eden özellikleri azaltır.
<pre>make_model_pipeline(...) return Pipeline([("preprocess", make_preprocessor(...)), ("mrmr", MRMRSelector(...)), ("model", estimator),])</pre>	On işleme, MRMR özellik seçimi ve modeli tek sklearn pipeline içinde birleştirir; böylece veri sızıntısı riski azaltılır.
<pre>optimize_model(...) sampler = optuna.samplers.TPESampler(seed=seed) study.optimize(objective, n_trials=trials)</pre>	Optuna TPE sampler ile hiperparametre optimizasyonu yapar. Objective fonksiyonunda StratifiedGroupKFold ve Macro-F1 kullanılır.
<pre>fit_pfit_calibrator(base_pipe, X_val, y_val) CalibratedClassifierCV(..., method="sigmoid", cv="pfit") calibrator.fit(X_val, y_val)</pre>	Eğitilmiş modeli validation seti üzerinde sigmoid calibration ile kalibre eder ve olasılık tahminlerinin güvenilirliğini artırmayı hedefler.
<pre>FittedSoftVotingEnsemble(ensemble_inputs) ensemble_inputs = {RF, ET, GB} proba = average(member.predict_proba(X))</pre>	RF, ET ve GB modellerinin olasılık çıktılarını ortalayarak soft voting ensemble modeli oluşturur.
<pre>metrics_from_proba(...) accuracy_score(y, pred) f1_score(y, pred, average="macro") roc_auc_score(y, proba) average_precision_score(y, proba)</pre>	Accuracy, precision, recall, F1, Macro-F1, ROC-AUC, PR-AUC, balanced accuracy ve Brier Score metriklerini hesaplar.
<pre>run_statistical_tests(cv_scores, output_path) friedmanchisquare(...) wilcoxon(...) p_value_bonferroni = min(1.0, p_value * correction)</pre>	Model performanslarını Friedman testi, Wilcoxon signed-rank testi ve Bonferroni düzeltmesi ile istatistiksel olarak karşılaştırır.

4. Modelleme

Kullanılan modeller:

- Logistic Regression
- RBF SVM
- Random Forest

- Extra Trees
- Gradient Boosting
- K-Nearest Neighbors
- Soft Voting Ensemble

5. Hiperparametre Optimizasyonu

Optuna kullanılarak her model için en az 50 trial denenmiştir. Amac fonksiyonu Macro-F1 olarak belirlenmiştir. Inner cross-validation yapısında StratifiedGroupKFold kullanılmıştır.

6. Sonuclar


Tablo 2. Final test seti model performanslari

model	accuracy	macro_f1	roc_auc	pr_auc	brier_score
LR	0.9235	0.8973	0.9459	0.9167	0.0635
SVM	0.9286	0.9048	0.9328	0.9067	0.0643
RF	0.8980	0.8580	0.9809	0.9583	0.0737
ET	0.9286	0.9048	0.9700	0.9464	0.0578
GB	0.9133	0.8866	0.9573	0.9272	0.0662
KNN	0.9337	0.9133	0.9296	0.9050	0.0624
MLP	0.9286	0.9095	0.9561	0.9313	0.0660
Ensemble	0.9184	0.8896	0.9805	0.9569	0.0617
WeightedEnsemble	0.9286	0.9048	0.9749	0.9502	0.0584

7. Grafikler


Bu bölümde final pipeline tarafından üretilen zorunlu grafikler sıralı olarak sunulmuştur.

Sekil 1. ROC egrisi




Yorum: ROC egrisi modellerin normal ve papilodem siniflarini genel olarak ayirma gucunu gostermektedir. Yuksek ROC-AUC degerleri, modellerin siniflari olasilik skorlarina gore basarili sekilde siralayabildigini desteklemektedir.

Sekil 2. Precision-Recall egrisi




Yorum: Precision-Recall egrisi, papilodem sinifinin normal sinifa gore daha az ornek icermesi nedeniyle ozellikle onemlidir. Yuksek PR-AUC degerleri, pozitif sinifin yakalanmasinda modellerin guclu performans gosterdiginin ortaya koymaktadır.

Sekil 3. Confusion matrix




Yorum: Confusion matrix, dogru ve hatali siniflandirmaların sinif bazında dagilimini gostermektedir. Diyagonal hucrelerdeki yogunluk modelin genel dogrulukunu, diyagonal disindaki hucreler ise yanlis siniflandirilan ornekleri temsil etmektedir.

Sekil 4. Feature importance grafigi




Yorum: Feature importance grafigi, model kararlarında en etkili radyomik ozellikleri siralamaktadır. Feature_0005 ozelliginin belirgin katkisi, sinif ayrimında bu ozelligin onemli bir ayirt edici bilgi tasidigini gostermektedir.

Sekil 5. Calibration curve



Yorum: Calibration curve, model olasilik tahminlerinin gercek pozitiflik oranlariyla ne kadar uyumlu oldugunu degerlendirmektedir. Egrilerin ideal dogruya yakin seyretmesi ve dusuk Brier Score degerleri, kalibrasyon sonrasi olasilik tahminlerinin makul duzeyde guvenilir oldugunu gostermektedir.

Sekil 6. Model karsilastirma grafigi



Yorum: Model karsilastirma grafigi, farkli algoritmaların test setindeki performansini bir arada sunmaktadır. Genel siniflandirma basarisi acisindan KNN modeli one cikarken, RF ve ensemble modelleri olasilik bazli ayirt edicilik metriklerinde guclu sonuclar vermistir.

8. Istatistiksel Analiz

Tablo 4. Istatistiksel test sonuclari

test	comparison	statistic	p_value	p_value_bonferroni
Friedman	all_models	7.8495	0.3461	0.3461
Wilcoxon signed-rank	Ensemble vs ET	5.5000	0.7500	1.0000
Wilcoxon signed-rank	Ensemble vs GB	7.0000	1.0000	1.0000
Wilcoxon signed-rank	Ensemble vs KNN	7.0000	1.0000	1.0000
Wilcoxon signed-rank	Ensemble vs LR	5.0000	0.6250	1.0000
Wilcoxon signed-rank	Ensemble vs MLP	5.0000	0.6250	1.0000
Wilcoxon signed-rank	Ensemble vs RF	7.0000	1.0000	1.0000
Wilcoxon signed-rank	Ensemble vs SVM	6.0000	0.8125	1.0000

9. Tartisma

- En iyi performansi hangi model verdi?

Final test sonuçlarına göre en yüksek Macro-F1 ve Accuracy değerleri KNN modeli ile elde edilmiştir. Bu nedenle genel sınıflandırma performansı açısından en başarılı model KNN olarak değerlendirilmiştir.

- Ensemble model tekli modellerden daha iyi mi?

Soft voting ensemble modeli ROC-AUC ve PR-AUC açısından çok güçlü sonuçlar vermiştir. Ancak Macro-F1 açısından KNN modelinin gerisinde kalmıştır. Bu nedenle ensemble modelin olasılık bazlı ayırt edicilikte başarılı olduğu, fakat genel sınıflandırma başarısında en iyi tekil modeli geçemediği söylenebilir.

- MRMR özellik seçimi performansa nasıl etki etti?

MRMR özellik seçimi, yüksek boyutlu 746 radyomik özellik arasından daha bilgilendirici ve daha az tekrar eden özelliklerin seçilmesini sağlamıştır. Bu yaklaşım modelin gereksiz ve yüksek korelasyonlu özelliklerden etkilenmesini azaltarak daha kararlı bir öğrenme süreci sağlamıştır.

- Kalibrasyon model güvenilirliğini artırdı mı?

Sigmoid kalibrasyon, modellerin olasılık çıktılarının daha güvenilir hale getirilmesi amacıyla uygulanmıştır. Brier Score değerlerinin genel olarak düşük seviyede olması, kalibrasyon sonrasında olasılık tahminlerinin makul düzeyde güvenilir olduğunu göstermektedir.

ROC-AUC değerleri modellerin sınıfları genel olarak iyi ayırabildiğini göstermiştir. PR-AUC değerleri özellikle papilödem sınıfının daha az sayıda örnek içermesi nedeniyle önemlidir. Random Forest ve ensemble modellerinin hem ROC-AUC hem de PR-AUC değerlerinin yüksek olması, bu modellerin sınıf ayrımında ve pozitif sınıfı yakalamada güçlü olduğunu göstermektedir.

- Yüksek boyutlu veri yapısı model performansını nasıl etkiledi?

Veri setinde 746 radyomik özellik bulunması, örnek sayısına göre yüksek boyutlu bir yapı oluşturmaktadır. Bu durum aşırı öğrenme riskini artırabilir. Bu nedenle düşük varyanslı özelliklerin silinmesi, korelasyon temelli eleme ve MRMR özellik seçimi gibi boyut azaltıcı adımlar model performansı ve genellenebilirlik açısından kritik öneme sahiptir.

- En önemli 10 radiomics özelliği hangileridir?

Feature importance analizine göre en önemli özellikler Feature_0005, Feature_0040, Feature_0436, Feature_0224, Feature_0570, Feature_0670, Feature_0592, Feature_0164, Feature_0022 ve

Feature_0478 olarak belirlenmiştir.

Final feature importance analizinde en yüksek katkıya sahip özellik Feature_0005 olmuştur (importance = 0.658023). Bu özelliği Feature_0040 (0.049211), Feature_0436 (0.034976), Feature_0224 (0.031259) ve Feature_0570 (0.030640) izlemiştir. Feature_0005'in diğer özelliklere göre belirgin şekilde yüksek önem değerine sahip olması, model kararlarında bu radyomik özelliğin baskın bir rol oynadığını göstermektedir.

Tablo 3. En önemli 10 radyomik özellik

feature	importance
Feature_0005	0.6580
Feature_0040	0.0492
Feature_0436	0.0350
Feature_0224	0.0313
Feature_0570	0.0306
Feature_0670	0.0261
Feature_0592	0.0260
Feature_0164	0.0236
Feature_0022	0.0221
Feature_0478	0.0145

10. Sonuc

Bu calismada veri sızıntısını engelleyen hasta seviyesinde bir makine ogrenmesi pipeline'i kurulmuştur. Elde edilen sonuclar, radyomik ozelliklerin papilodem siniflandirmasinda kullanilabilirliğini degerlendirmek icin raporlanmistir.

Final test seti sonuclarına göre en yüksek Macro-F1 skoru KNN modeli ile elde edilmiştir (Macro-F1 = 0.9133). KNN modeli ayrıca en yüksek doğruluk değerini vermiştir (Accuracy = 0.9337). Bu sonuç, KNN modelinin test setindeki genel sınıflandırma performansının diğer modellere göre daha güçlü olduğunu göstermektedir.

ROC-AUC açısından en başarılı model Random Forest olmuştur (ROC-AUC = 0.9809). PR-AUC metriğinde de en yüksek değer Random Forest modeli ile elde edilmiştir (PR-AUC = 0.9583). Bu durum Random Forest modelinin olasılık skorlarını sınıfları ayıracak şekilde güçlü biçimde sıralayabildiğini göstermektedir.

RF, ET ve GB modellerinden oluşturulan soft voting ensemble modeli de güçlü bir performans göstermiştir (Macro-F1 = 0.8896, ROC-AUC = 0.9805, PR-AUC = 0.9569). Ancak ensemble model, Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir. Buna karşın ROC-AUC ve PR-AUC değerleri Random Forest sonucuna oldukça yakın olduğu için ensemble modelin olasılık bazlı ayırt edicilik açısından başarılı olduğu söylenebilir.

Bu çalışmada radyomik özellikler kullanılarak normal ve papilödem sınıflarını ayırmaya yönelik hasta seviyesinde veri sızıntısını önleyen bir makine öğrenmesi pipeline'ı geliştirilmiştir. Veri ön işleme, düşük varyans ve korelasyon temelli özellik eleme, MRMR özellik seçimi, Optuna tabanlı hiperparametre optimizasyonu, sigmoid kalibrasyon ve soft voting ensemble adımları uygulanmıştır.

Final test sonuclarına göre genel siniflandırma performansı açısından en başarılı model KNN olmuştur. Random Forest modeli ise ROC-AUC ve PR-AUC metriklerinde en yüksek sonucları

vermiştir. Ensemble model güçlü olasılık bazlı ayırt edicilik göstermesine rağmen Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir.

Elde edilen bulgular, radyomik özelliklerin papilödem sınıflandırmasında anlamlı ayırt edici bilgi taşıdığını göstermektedir. Bununla birlikte veri setinin yüksek boyutlu olması nedeniyle özellik seçimi ve hasta seviyesinde doğrulama adımları modelin güvenilirliği açısından kritik öneme sahiptir.

11. Kaynakça

- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Akiba, T. et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. Proceedings of the 25th ACM SIGKDD International Conference.
- van Griethuysen, J. J. M. et al. (2017). Computational Radiomics System to Decode the Radiographic Phenotype. Cancer Research, 77(21), e104-e107.
- Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images Are More than Pictures, They Are Data. Radiology, 278(2), 563-577.
- scikit-learn documentation: <https://scikit-learn.org/>
- Optuna documentation: <https://optuna.org/>

12. Bonus Calismalar

Bu bolumde odevde bonus olarak belirtilen SHAP, LIME, nested cross-validation, deep learning modeli, feature stability, ensemble optimizasyonu ve threshold optimization calismalarinin uretilen tablo ve gorsel sonuclari sunulmustur.

Tablo 5. Deep learning MLP model sonucu

model	accuracy	macro_f1	roc_auc	pr_auc	brier_score
MLP	0.9286	0.9095	0.9561	0.9313	0.0660

Tablo 6. SHAP analizinde en etkili ozellikler

feature	mean_abs_shap
Feature_0005	2.7414
Feature_0164	2.3737
Feature_0436	1.5701
Feature_0028	0.9571
Feature_0688	0.8988
Feature_0670	0.7833
Feature_0571	0.6436
Feature_0478	0.6373
Feature_0022	0.6229
Feature_0135	0.4871

Tablo 7. LIME lokal aciklama agirliklari

model	test_index	feature_rule	lime_weight
GB	154.0000	Feature_0005 > 0.78	0.4993
GB	154.0000	Feature_0164 > 0.67	0.1662
GB	154.0000	Feature_0043 <= 0.00	0.1606
GB	154.0000	Feature_0436 > 0.51	0.1352
GB	154.0000	Feature_0022 > 0.53	0.1047
GB	154.0000	Feature_0478 > 0.59	0.0891
GB	154.0000	Feature_0224 <= -0.57	0.0879
GB	154.0000	Feature_0491 <= -0.45	0.0536
GB	154.0000	Feature_0034 <= -0.47	-0.0529
GB	154.0000	Feature_0040 > 0.67	0.0402

Tablo 8. Nested cross-validation dis fold sonuclari

fold	selected_model	inner_best_macro_f1	outer_macro_f1	outer_roc_auc	outer_pr_auc
1.0000	RF	0.9476	0.7752	0.8075	0.7905
2.0000	GB	0.8653	0.8999	0.9476	0.9408
3.0000	MLP	0.8370	0.8548	0.9984	0.9965

Tablo 9. Feature stability analizinde en stabil ozellikler

feature	selection_count	n_folds	stability_percent
Feature_0022	5.0000	5.0000	100.0000
Feature_0027	5.0000	5.0000	100.0000
Feature_0040	5.0000	5.0000	100.0000
Feature_0043	5.0000	5.0000	100.0000
Feature_0135	5.0000	5.0000	100.0000
Feature_0166	5.0000	5.0000	100.0000
Feature_0224	5.0000	5.0000	100.0000
Feature_0368	5.0000	5.0000	100.0000
Feature_0408	5.0000	5.0000	100.0000
Feature_0478	5.0000	5.0000	100.0000


Tablo 10. Ensemble agirlik optimizasyonu

rf_weight	et_weight	gb_weight	validation_macro_f1	test_macro_f1	test_roc_auc	test_pr_auc
0.1000	0.8000	0.1000	0.8446	0.9048	0.9749	0.9502

Tablo 11. Threshold optimization sonuclari


model	best_threshold	validation_macro_f1	test_macro_f1	test_recall	test_precision
SVM	0.5200	0.8601	0.9048	0.7500	1.0000
KNN	0.6900	0.8661	0.9048	0.7500	1.0000
LR	0.5400	0.8520	0.8973	0.7321	1.0000
MLP	0.8300	0.8580	0.8896	0.7143	1.0000
GB	0.7000	0.8520	0.8836	0.7143	0.9756
ET	0.7200	0.8661	0.8819	0.6964	1.0000
WeightedEnsemble	0.7200	0.8580	0.8819	0.6964	1.0000
Ensemble	0.7500	0.8580	0.8580	0.6429	1.0000
RF	0.8000	0.8580	0.8497	0.6250	1.0000

Sekil 7. SHAP özellik etkisi analizi




Yorum: SHAP analizi, model tahminlerine en fazla katkıda bulunan özellikleri açıklamaktadır. Bu analiz, feature importance sonuçlarıyla birlikte yorumlandığında model kararlarının hangi radyomik değişkenlere dayandığını daha anlaşılır hale getirmektedir.

Sekil 8. LIME lokal açıklanabilirlik analizi




Yorum: LIME analizi, seçilen tek bir test örneği için model kararını lokal olarak açıklamaktadır. Bu grafik, ilgili örnekte hangi özellik aralıklarının papilodem veya normal sınıf tahminini desteklediğini göstererek model yorumlanabilirliğini artırmaktadır.

Sekil 9. Nested cross-validation sonuclari




Yorum: Nested cross-validation sonuclari, model secimi ve performans tahmininin daha tarafsiz degerlendirilmesini saglamaktadir. Dis fold sonuclarinin birlikte raporlanmasi, model performansinin farkli hasta gruplari üzerindeki kararliligini incelemeye yardim eder.

Sekil 10. Feature stability analizi




Yorum: Feature stability analizi, farkli cross-validation foldlarinda secilen ozelliklerin ne kadar tutarli oldugunu gostermektedir. Yuksek stabiliteye sahip ozellikler, modelin yalnızca tek bir bolunmeye bagli olmayan daha guvenilir sinyaller kullandigini destekler.

Sekil 11. Ensemble agirlik optimizasyonu



Yorum: Ensemble optimizasyonu, RF, ET ve GB modellerinin soft voting yapısındaki ağırlıklarını validation performansına göre ayarlamaktadır. Bu yaklaşım, ensemble modelin tüm üyeleri eşit kabul etmek yerine daha etkili modellerden daha fazla yararlanmasını sağlamaktadır.

Sekil 12. Threshold optimization sonuclari



Yorum: Threshold optimization analizi, varsayılan 0.50 karar esigi yerine validation setinde daha uygun esiklerin denenmesini sağlamaktadır. Bu işlem, precision ve recall arasındaki dengeyi klinik önceliklere göre ayarlamak için kullanılabilir.