

# Radyomik Özellikler Kullanılarak Papilodem Sınıflandırması

## 1. Giriş

Bu çalışmanın amacı, radyomik özellikler kullanılarak Normal ve Papilodem sınıflarının makine öğrenmesi yöntemleri ile ayrılmasıdır. Problem ikili sınıflandırma problemidir.

## 2. Veri Seti

Veri seti iki CSV dosyasından oluşmaktadır:

- normal\_radiomics.csv
- papilodem\_radiomics.csv

Her örnekte 746 radyomik özellik bulunmaktadır.

Hasta bazlı veri bölme kullanılmıřtır; böylece aynı hastaya ait örneklerin farklı train, validation veya test setlerine düşmesi engellenmiştir.

Çalışmada toplam 966 örnekten oluşan bir radyomik veri seti kullanılmıştır. Veri setinde 69 hasta bulunmaktadır. Normal sınıfında 672 örnek ve 48 hasta, papilodem sınıfında ise 294 örnek ve 21 hasta yer almaktadır. Her örnek için 746 radyomik özellik bulunmaktadır. Veri setinde eksik değer ve tekrarlı satır bulunmamaktadır.

Veri seti hasta seviyesinde train, validation ve test alt kümelerine ayrılmıştır. Eğitim setinde 574 örnek ve 41 hasta, validation setinde 196 örnek ve 14 hasta, test setinde ise 196 örnek ve 14 hasta bulunmaktadır. Bu ayırmada aynı hastaya ait örneklerin farklı alt kümelere düşmemesine dikkat edilmiştir.

## 3. Metodoloji

Çalışmada şu pipeline uygulanmıştır:

1. Veri setlerinin birleştirilmesi.
2. Sınıf etiketlerinin oluşturulması.
3. Hasta seviyesinde train / validation / test ayrımı.
4. Median imputation.
5. Low-variance filtering.
6. Pearson correlation  $> 0.95$  olan özelliklerin elenmesi.
7. RobustScaler ile ölçekleme.
8. MRMR özellik seçimi.
9. Optuna TPE sampler ile hiperparametre optimizasyonu.
10. Model eğitimi.
11. Sigmoid calibration.
12. RF, ET ve GB ile soft voting ensemble.

Bu çalışmada veri sızıntısını önlemek amacıyla tüm ön işleme ve özellik seçimi adımları makine öğrenmesi pipeline'ı içerisinde uygulanmıştır. Median imputation, düşük varyanslı özelliklerin

elenmesi, korelasyon temelli özellik azaltma, RobustScaler ile ölçekleme ve MRMR özellik seçimi eğitim verisi üzerinde fit edilmiştir. Test verisi yalnızca final değerlendirme aşamasında kullanılmıştır.

Model seçimi ve hiperparametre optimizasyonu için StratifiedGroupKFold yapısı kullanılmıştır. Böylece sınıf dağılımı korunurken aynı hastaya ait örneklerin farklı foldlara düşmesi engellenmiştir. Optuna TPE sampler ile her model için 50 trial gerçekleştirilmiş ve amaç fonksiyonu Macro-F1 olarak belirlenmiştir.

## 4. Modelleme

Kullanılan modeller:

- Logistic Regression
- RBF SVM
- Random Forest
- Extra Trees
- Gradient Boosting
- K-Nearest Neighbors
- Soft Voting Ensemble

## 5. Hiperparametre Optimizasyonu

Optuna kullanılarak her model için en az 50 trial denenmiştir. Amac fonksiyonu Macro-F1 olarak belirlenmiştir. Inner cross-validation yapısında StratifiedGroupKFold kullanılmıştır.

## 6. Sonuclar


**Tablo 1. Final test seti model performanslari**

| model            | accuracy | macro_f1 | roc_auc | pr_auc | brier_score |
|------------------|----------|----------|---------|--------|-------------|
| LR               | 0.9235   | 0.8973   | 0.9459  | 0.9167 | 0.0635      |
| SVM              | 0.9286   | 0.9048   | 0.9328  | 0.9067 | 0.0643      |
| RF               | 0.8980   | 0.8580   | 0.9809  | 0.9583 | 0.0737      |
| ET               | 0.9286   | 0.9048   | 0.9700  | 0.9464 | 0.0578      |
| GB               | 0.9133   | 0.8866   | 0.9573  | 0.9272 | 0.0662      |
| KNN              | 0.9337   | 0.9133   | 0.9296  | 0.9050 | 0.0624      |
| MLP              | 0.9286   | 0.9095   | 0.9561  | 0.9313 | 0.0660      |
| Ensemble         | 0.9184   | 0.8896   | 0.9805  | 0.9569 | 0.0617      |
| WeightedEnsemble | 0.9286   | 0.9048   | 0.9749  | 0.9502 | 0.0584      |


## 7. Grafikler

Bu bölümde final pipeline tarafından üretilen zorunlu grafikler sıralı olarak sunulmuştur.


## Sekil 1. ROC egrisi




## Sekil 2. Precision-Recall egrisi




### Sekil 3. Confusion matrix




### Sekil 4. Feature importance grafigi



## Sekil 5. Calibration curve



## Sekil 6. Model karsilastirma grafigi



## 8. Istatistiksel Analiz

Tablo 3. Istatistiksel test sonuclari

| test                 | comparison      | statistic | p_value | p_value_bonferroni |
|----------------------|-----------------|-----------|---------|--------------------|
| Friedman             | all_models      | 7.8495    | 0.3461  | 0.3461             |
| Wilcoxon signed-rank | Ensemble vs ET  | 5.5000    | 0.7500  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs GB  | 7.0000    | 1.0000  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs KNN | 7.0000    | 1.0000  | 1.0000             |

| test                 | comparison      | statistic | p_value | p_value_bonferroni |
|----------------------|-----------------|-----------|---------|--------------------|
| Wilcoxon signed-rank | Ensemble vs LR  | 5.0000    | 0.6250  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs MLP | 5.0000    | 0.6250  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs RF  | 7.0000    | 1.0000  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs SVM | 6.0000    | 0.8125  | 1.0000             |

## 9. Tartisma

- En iyi performansi hangi model verdi?

Final test sonuçlarına göre en yüksek Macro-F1 ve Accuracy değerleri KNN modeli ile elde edilmiştir. Bu nedenle genel sınıflandırma performansı açısından en başarılı model KNN olarak değerlendirilmiştir.

- Ensemble model tekli modellerden daha iyi mi?

Soft voting ensemble modeli ROC-AUC ve PR-AUC açısından çok güçlü sonuçlar vermiştir. Ancak Macro-F1 açısından KNN modelinin gerisinde kalmıştır. Bu nedenle ensemble modelin olasılık bazlı ayırt edicilikte başarılı olduğu, fakat genel sınıflandırma başarısında en iyi tekil modeli geçemediği söylenebilir.

- MRMR özellik seçimi performansa nasıl etki etti?

MRMR özellik seçimi, yüksek boyutlu 746 radyomik özellik arasından daha bilgilendirici ve daha az tekrar eden özelliklerin seçilmesini sağlamıştır. Bu yaklaşım modelin gereksiz ve yüksek korelasyonlu özelliklerden etkilenmesini azaltarak daha kararlı bir öğrenme süreci sağlamıştır.

- Kalibrasyon model güvenilirliğini artırdı mı?

Sigmoid kalibrasyon, modellerin olasılık çıktılarının daha güvenilir hale getirilmesi amacıyla uygulanmıştır. Brier Score değerlerinin genel olarak düşük seviyede olması, kalibrasyon sonrasında olasılık tahminlerinin makul düzeyde güvenilir olduğunu göstermektedir.

ROC-AUC değerleri modellerin sınıfları genel olarak iyi ayırabildiğini göstermiştir. PR-AUC değerleri özellikle papilödem sınıfının daha az sayıda örnek içermesi nedeniyle önemlidir. Random Forest ve ensemble modellerinin hem ROC-AUC hem de PR-AUC değerlerinin yüksek olması, bu modellerin sınıf ayırımında ve pozitif sınıfı yakalamada güçlü olduğunu göstermektedir.

- Yüksek boyutlu veri yapısı model performansını nasıl etkiledi?

Veri setinde 746 radyomik özellik bulunması, örnek sayısına göre yüksek boyutlu bir yapı oluşturmaktadır. Bu durum aşırı öğrenme riskini artırabilir. Bu nedenle düşük varyanslı özelliklerin silinmesi, korelasyon temelli eleme ve MRMR özellik seçimi gibi boyut azaltıcı adımlar model performansı ve genellenebilirlik açısından kritik öneme sahiptir.

- En önemli 10 radiomics özelliği hangileridir?

Feature importance analizine göre en önemli özellikler Feature\_0005, Feature\_0040, Feature\_0436, Feature\_0224, Feature\_0570, Feature\_0670, Feature\_0592, Feature\_0164, Feature\_0022 ve Feature\_0478 olarak belirlenmiştir.

Final feature importance analizinde en yüksek katkıya sahip özellik Feature\_0005 olmuştur (importance = 0.658023). Bu özelliği Feature\_0040 (0.049211), Feature\_0436 (0.034976), Feature\_0224 (0.031259) ve Feature\_0570 (0.030640) izlemiştir. Feature\_0005'in diğer özelliklere göre belirgin şekilde yüksek önem değerine sahip olması, model kararlarında bu radyomik özelliğin

baskın bir rol oynadığını göstermektedir.

**Tablo 2. En önemli 10 radyomik özellik**

| feature      | importance |
|--------------|------------|
| Feature_0005 | 0.6580     |
| Feature_0040 | 0.0492     |
| Feature_0436 | 0.0350     |
| Feature_0224 | 0.0313     |
| Feature_0570 | 0.0306     |
| Feature_0670 | 0.0261     |
| Feature_0592 | 0.0260     |
| Feature_0164 | 0.0236     |
| Feature_0022 | 0.0221     |
| Feature_0478 | 0.0145     |

## 10. Sonuc

Bu calismada veri sızıntısını engelleyen hasta seviyesinde bir makine ogrenmesi pipeline'i kurulmustur. Elde edilen sonuclar, radyomik ozelliklerin papilodem siniflandirmasinda kullanilabilirliğini degerlendirmek icin raporlanmistir.

Final test seti sonuclarına göre en yüksek Macro-F1 skoru KNN modeli ile elde edilmiştir (Macro-F1 = 0.9133). KNN modeli ayrıca en yüksek doğruluk değerini vermiştir (Accuracy = 0.9337). Bu sonuç, KNN modelinin test setindeki genel sınıflandırma performansının diğer modellere göre daha güçlü olduğunu göstermektedir.

ROC-AUC açısından en başarılı model Random Forest olmuştur (ROC-AUC = 0.9809). PR-AUC metriğinde de en yüksek değer Random Forest modeli ile elde edilmiştir (PR-AUC = 0.9583). Bu durum Random Forest modelinin olasılık skorlarını sınıfları ayıracak şekilde güçlü biçimde sıralayabildiğini göstermektedir.

RF, ET ve GB modellerinden oluşturulan soft voting ensemble modeli de güçlü bir performans göstermiştir (Macro-F1 = 0.8896, ROC-AUC = 0.9805, PR-AUC = 0.9569). Ancak ensemble model, Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir. Buna karşın ROC-AUC ve PR-AUC değerleri Random Forest sonucuna oldukça yakın olduğu için ensemble modelin olasılık bazlı ayırt edicilik açısından başarılı olduğu söylenebilir.

Bu çalışmada radyomik özellikler kullanılarak normal ve papilödem sınıflarını ayırmaya yönelik hasta seviyesinde veri sızıntısını önleyen bir makine öğrenmesi pipeline'ı geliştirilmiştir. Veri ön işleme, düşük varyans ve korelasyon temelli özellik eleme, MRMR özellik seçimi, Optuna tabanlı hiperparametre optimizasyonu, sigmoid kalibrasyon ve soft voting ensemble adımları uygulanmıştır.

Final test sonuclarına göre genel sınıflandırma performansı açısından en başarılı model KNN olmuştur. Random Forest modeli ise ROC-AUC ve PR-AUC metriklerinde en yüksek sonuçları vermiştir. Ensemble model güçlü olasılık bazlı ayırt edicilik göstermesine rağmen Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir.

Elde edilen bulgular, radyomik özelliklerin papilödem sınıflandırmasında anlamlı ayırt edici bilgi taşıdığını göstermektedir. Bununla birlikte veri setinin yüksek boyutlu olması nedeniyle özellik seçimi ve hasta seviyesinde doğrulama adımları modelin güvenilirliği açısından kritik öneme sahiptir.

## 11. Kaynakca

- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Akiba, T. et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. Proceedings of the 25th ACM SIGKDD International Conference.
- van Griethuysen, J. J. M. et al. (2017). Computational Radiomics System to Decode the Radiographic Phenotype. Cancer Research, 77(21), e104-e107.
- Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images Are More than Pictures, They Are Data. Radiology, 278(2), 563-577.
- scikit-learn documentation: <https://scikit-learn.org/>
- Optuna documentation: <https://optuna.org/>



## 12. Bonus Calismalar

Bu bolumde odevde bonus olarak belirtilen SHAP, LIME, nested cross-validation, deep learning modeli, feature stability, ensemble optimizasyonu ve threshold optimization calismalarinin uretilen tablo ve gorsel sonuclari sunulmustur.

**Tablo 4. Deep learning MLP model sonucu**

| model | accuracy | macro_f1 | roc_auc | pr_auc | brier_score |
|-------|----------|----------|---------|--------|-------------|
| MLP   | 0.9286   | 0.9095   | 0.9561  | 0.9313 | 0.0660      |

**Tablo 5. SHAP analizinde en etkili ozellikler**

| feature      | mean_abs_shap |
|--------------|---------------|
| Feature_0005 | 2.7414        |
| Feature_0164 | 2.3737        |
| Feature_0436 | 1.5701        |
| Feature_0028 | 0.9571        |
| Feature_0688 | 0.8988        |
| Feature_0670 | 0.7833        |
| Feature_0571 | 0.6436        |
| Feature_0478 | 0.6373        |
| Feature_0022 | 0.6229        |
| Feature_0135 | 0.4871        |

**Tablo 6. LIME lokal aciklama agirliklari**

| model | test_index | feature_rule          | lime_weight |
|-------|------------|-----------------------|-------------|
| GB    | 154.0000   | Feature_0005 > 0.78   | 0.4993      |
| GB    | 154.0000   | Feature_0164 > 0.67   | 0.1662      |
| GB    | 154.0000   | Feature_0043 <= 0.00  | 0.1606      |
| GB    | 154.0000   | Feature_0436 > 0.51   | 0.1352      |
| GB    | 154.0000   | Feature_0022 > 0.53   | 0.1047      |
| GB    | 154.0000   | Feature_0478 > 0.59   | 0.0891      |
| GB    | 154.0000   | Feature_0224 <= -0.57 | 0.0879      |
| GB    | 154.0000   | Feature_0491 <= -0.45 | 0.0536      |
| GB    | 154.0000   | Feature_0034 <= -0.47 | -0.0529     |
| GB    | 154.0000   | Feature_0040 > 0.67   | 0.0402      |

**Tablo 7. Nested cross-validation dis fold sonuclari**

| fold   | selected_model | inner_best_macro_f1 | outer_macro_f1 | outer_roc_auc | outer_pr_auc |
|--------|----------------|---------------------|----------------|---------------|--------------|
| 1.0000 | RF             | 0.9476              | 0.7752         | 0.8075        | 0.7905       |
| 2.0000 | GB             | 0.8653              | 0.8999         | 0.9476        | 0.9408       |
| 3.0000 | MLP            | 0.8370              | 0.8548         | 0.9984        | 0.9965       |

**Tablo 8. Feature stability analizinde en stabil ozellikler**

| feature      | selection_count | n_folds | stability_percent |
|--------------|-----------------|---------|-------------------|
| Feature_0022 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0027 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0040 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0043 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0135 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0166 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0224 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0368 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0408 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0478 | 5.0000          | 5.0000  | 100.0000          |


**Tablo 9. Ensemble agirlik optimizasyonu**

| rf_weight | et_weight | gb_weight | validation_macro_f1 | test_macro_f1 | test_roc_auc | test_pr_auc |
|-----------|-----------|-----------|---------------------|---------------|--------------|-------------|
| 0.1000    | 0.8000    | 0.1000    | 0.8446              | 0.9048        | 0.9749       | 0.9502      |


**Tablo 10. Threshold optimization sonuclari**

| model            | best_threshold | validation_macro_f1 | test_macro_f1 | test_recall | test_precision |
|------------------|----------------|---------------------|---------------|-------------|----------------|
| SVM              | 0.5200         | 0.8601              | 0.9048        | 0.7500      | 1.0000         |
| KNN              | 0.6900         | 0.8661              | 0.9048        | 0.7500      | 1.0000         |
| LR               | 0.5400         | 0.8520              | 0.8973        | 0.7321      | 1.0000         |
| MLP              | 0.8300         | 0.8580              | 0.8896        | 0.7143      | 1.0000         |
| GB               | 0.7000         | 0.8520              | 0.8836        | 0.7143      | 0.9756         |
| ET               | 0.7200         | 0.8661              | 0.8819        | 0.6964      | 1.0000         |
| WeightedEnsemble | 0.7200         | 0.8580              | 0.8819        | 0.6964      | 1.0000         |
| Ensemble         | 0.7500         | 0.8580              | 0.8580        | 0.6429      | 1.0000         |
| RF               | 0.8000         | 0.8580              | 0.8497        | 0.6250      | 1.0000         |


## Sekil 7. SHAP özellik etkisi analizi



## Sekil 8. LIME lokal aciklanabilirlik analizi




## Sekil 9. Nested cross-validation sonuclari



## Sekil 10. Feature stability analizi



### Sekil 11. Ensemble agirlik optimizasyonu



### Sekil 12. Threshold optimization sonuclari

