

# Radyomik Özellikler Kullanılarak Papilodem Sınıflandırması

## 1. Giriş

Bu çalışmanın amacı, radyomik özellikler kullanılarak Normal ve Papilodem sınıflarının makine öğrenmesi yöntemleri ile ayrılmasıdır. Problem ikili sınıflandırma problemidir.

## 2. Veri Seti

Veri seti iki CSV dosyasından oluşmaktadır:

- normal\_radiomics.csv
- papilodem\_radiomics.csv

Her örnekte 746 radyomik özellik bulunmaktadır.

Hasta bazlı veri bölme kullanılmıřtır; böylece aynı hastaya ait örneklerin farklı train, validation veya test setlerine düşmesi engellenmiştir.

Çalışmada toplam 966 örnekten oluşan bir radyomik veri seti kullanılmıştır. Veri setinde 69 hasta bulunmaktadır. Normal sınıfında 672 örnek ve 48 hasta, papilodem sınıfında ise 294 örnek ve 21 hasta yer almaktadır. Her örnek için 746 radyomik özellik bulunmaktadır. Veri setinde eksik değer ve tekrarlı satır bulunmamaktadır.

Veri seti hasta seviyesinde train, validation ve test alt kümelerine ayrılmıştır. Eğitim setinde 574 örnek ve 41 hasta, validation setinde 196 örnek ve 14 hasta, test setinde ise 196 örnek ve 14 hasta bulunmaktadır. Bu ayırmada aynı hastaya ait örneklerin farklı alt kümelere düşmemesine dikkat edilmiştir.

## 3. Metodoloji

Çalışmada şu pipeline uygulanmıştır:

1. Veri setlerinin birleştirilmesi.
2. Sınıf etiketlerinin oluşturulması.
3. Hasta seviyesinde train / validation / test ayrımı.
4. Median imputation.
5. Low-variance filtering.
6. Pearson correlation  $> 0.95$  olan özelliklerin elenmesi.
7. RobustScaler ile ölçekleme.
8. MRMR özellik seçimi.
9. Optuna TPE sampler ile hiperparametre optimizasyonu.
10. Model eğitimi.
11. Sigmoid calibration.
12. RF, ET ve GB ile soft voting ensemble.

Bu çalışmada veri sızıntısını önlemek amacıyla tüm ön işleme ve özellik seçimi adımları makine öğrenmesi pipeline'ı içerisinde uygulanmıştır. Median imputation, düşük varyanslı özelliklerin

elenmesi, korelasyon temelli özellik azaltma, RobustScaler ile ölçekleme ve MRMR özellik seçimi eğitim verisi üzerinde fit edilmiştir. Test verisi yalnızca final değerlendirme aşamasında kullanılmıştır.

Model seçimi ve hiperparametre optimizasyonu için StratifiedGroupKFold yapısı kullanılmıştır. Böylece sınıf dağılımı korunurken aynı hastaya ait örneklerin farklı foldlara düşmesi engellenmiştir. Optuna TPE sampler ile her model için 50 trial gerçekleştirilmiş ve amaç fonksiyonu Macro-F1 olarak belirlenmiştir.

Kod açıklamaları ve ilgili dosyalar:

- `load_dataset`: Normal ve papilödem CSV dosyalarını okur, sınıf etiketlerini oluşturur ve iki veri setini birleştirir.
- `make_patient_level_splits`: Aynı hastaya ait örneklerin farklı alt kümelere düşmemesi için hasta seviyesinde train, validation ve test ayrımı yapar.
- `make_preprocessor`: Median imputation, low-variance filtering, Pearson korelasyon eleme ve RobustScaler adımlarını tek bir ön işleme pipeline'ı içinde uygular.
- `MRMRSelector`: Mutual information ve Pearson korelasyon temelli MRMR özellik seçimi yaparak en bilgilendirici radyomik özellikleri seçer.
- `build_pipeline_from_params`: Ön işleme, MRMR özellik seçimi ve makine öğrenmesi modelini tek bir sklearn pipeline yapısında birleştirir.
- `optimize_model`: Optuna TPE sampler ile hiperparametre optimizasyonu yapar ve amaç fonksiyonu olarak Macro-F1 skorunu kullanır.
- `fit_prefit_calibrator`: Validation seti üzerinde sigmoid calibration uygulayarak model olasılık tahminlerini kalibre eder.
- `FittedSoftVotingEnsemble`: RF, ET ve GB modellerinin olasılık çıktılarını ortalayarak soft voting ensemble modeli oluşturur.
- `FittedWeightedSoftVotingEnsemble`: Bonus çalışma kapsamında ensemble üyelerine optimize edilmiş ağırlıklar vererek weighted ensemble modeli oluşturur.
- `metrics_from_proba`: Accuracy, precision, recall, F1, Macro-F1, ROC-AUC, PR-AUC, balanced accuracy ve Brier Score metriklerini hesaplar.
- `run_statistical_tests`: Friedman testi, Wilcoxon signed-rank testi ve Bonferroni düzeltmesi ile modelleri istatistiksel olarak karşılaştırır.
- `run_shap_analysis` ve `run_lime_analysis`: Bonus açıklanabilirlik analizleri ile model kararlarının hangi özelliklerden etkilendiğini gösterir.
- `scripts/build_academic_report_pdf.py`: Oluşturulan tablo ve grafik çıktılarını kullanarak final akademik PDF raporunu üretir.

## 4. Modelleme

Kullanılan modeller:

- Logistic Regression
- RBF SVM
- Random Forest
- Extra Trees
- Gradient Boosting
- K-Nearest Neighbors
- Soft Voting Ensemble

## 5. Hiperparametre Optimizasyonu

Optuna kullanılarak her model için en az 50 trial denenmiştir. Amac fonksiyonu Macro-F1 olarak belirlenmiştir. Inner cross-validation yapısında StratifiedGroupKFold kullanılmıştır.

## 6. Sonuclar


Tablo 1. Final test seti model performanslari

| model            | accuracy | macro_f1 | roc_auc | pr_auc | brier_score |
|------------------|----------|----------|---------|--------|-------------|
| LR               | 0.9235   | 0.8973   | 0.9459  | 0.9167 | 0.0635      |
| SVM              | 0.9286   | 0.9048   | 0.9328  | 0.9067 | 0.0643      |
| RF               | 0.8980   | 0.8580   | 0.9809  | 0.9583 | 0.0737      |
| ET               | 0.9286   | 0.9048   | 0.9700  | 0.9464 | 0.0578      |
| GB               | 0.9133   | 0.8866   | 0.9573  | 0.9272 | 0.0662      |
| KNN              | 0.9337   | 0.9133   | 0.9296  | 0.9050 | 0.0624      |
| MLP              | 0.9286   | 0.9095   | 0.9561  | 0.9313 | 0.0660      |
| Ensemble         | 0.9184   | 0.8896   | 0.9805  | 0.9569 | 0.0617      |
| WeightedEnsemble | 0.9286   | 0.9048   | 0.9749  | 0.9502 | 0.0584      |

## 7. Grafikler


Bu bolumde final pipeline tarafından uretilen zorunlu grafikler sirali olarak sunulmustur.

Sekil 1. ROC egrisi




Yorum: ROC egrisi modellerin normal ve papilodem siniflarini genel olarak ayirma gucunu gostermektedir. Yuksek ROC-AUC degerleri, modellerin siniflari olasilik skorlarina gore basarili sekilde siralayabildigini desteklemektedir.

## Sekil 2. Precision-Recall egrisi




Yorum: Precision-Recall egrisi, papilledem sinifinin normal sinifa gore daha az ornek icermesi nedeniyle ozellikle onemlidir. Yuksek PR-AUC degerleri, pozitif sinifin yakalanmasinda modellerin guclu performans gosterdiginin ortaya koymaktadir.

## Sekil 3. Confusion matrix




Yorum: Confusion matrix, dogru ve hatali siniflandirmalarin sinif bazinda dagilimini gstermektedir. Diyagonal hucrelerdeki yogunluk modelin genel dogrulukunu, diyagonal disindaki hucreler ise yanlis siniflandirilan ornekleri temsil etmektedir.

**Sekil 4. Feature importance grafigi**




Yorum: Feature importance grafigi, model kararlarında en etkili radyomik ozellikleri siralamaktadır. Feature\_0005 ozelliginin belirgin katkisi, sinif ayiriminda bu ozelligin onemli bir ayirt edici bilgi tasidigini gostermektedir.

**Sekil 5. Calibration curve**



Yorum: Calibration curve, model olasilik tahminlerinin gercek pozitiflik oranlariyla ne kadar uyumlu oldugunu degerlendirmektedir. Egrilerin ideal dogruya yakin seyretmesi ve dusuk Brier Score degerleri, kalibrasyon sonrasi olasilik tahminlerinin makul duzeyde guvenilir oldugunu gostermektedir.

**Sekil 6. Model karsilastirma grafigi**



Yorum: Model karsilastirma grafigi, farkli algoritmaların test setindeki performansini bir arada sunmaktadır. Genel siniflandirma basarisi acisindan KNN modeli one cikarken, RF ve ensemble modelleri olasilik bazli ayirt edicilik metriklerinde guclu sonuclar vermistir.

## 8. Istatistiksel Analiz

**Tablo 3. Istatistiksel test sonuclari**

| test                 | comparison      | statistic | p_value | p_value_bonferroni |
|----------------------|-----------------|-----------|---------|--------------------|
| Friedman             | all_models      | 7.8495    | 0.3461  | 0.3461             |
| Wilcoxon signed-rank | Ensemble vs ET  | 5.5000    | 0.7500  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs GB  | 7.0000    | 1.0000  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs KNN | 7.0000    | 1.0000  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs LR  | 5.0000    | 0.6250  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs MLP | 5.0000    | 0.6250  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs RF  | 7.0000    | 1.0000  | 1.0000             |
| Wilcoxon signed-rank | Ensemble vs SVM | 6.0000    | 0.8125  | 1.0000             |

## 9. Tartisma

- En iyi performansi hangi model verdi?

Final test sonuclarina gore en yuksek Macro-F1 ve Accuracy degerleri KNN modeli ile elde edilmiştir. Bu nedenle genel siniflandirma performansi acisindan en basarili model KNN olarak deđerlendirilmiştir.

- Ensemble model tekli modellerden daha iyi mi?

Soft voting ensemble modeli ROC-AUC ve PR-AUC açısından çok güçlü sonuçlar vermiştir. Ancak Macro-F1 açısından KNN modelinin gerisinde kalmıştır. Bu nedenle ensemble modelin olasılık bazlı ayırt edicilikte başarılı olduğu, fakat genel sınıflandırma başarısında en iyi tekil modeli geçemediği söylenebilir.

- MRMR özellik seçimi performansa nasıl etki etti?

MRMR özellik seçimi, yüksek boyutlu 746 radyomik özellik arasından daha bilgilendirici ve daha az tekrar eden özelliklerin seçilmesini sağlamıştır. Bu yaklaşım modelin gereksiz ve yüksek korelasyonlu özelliklerden etkilenmesini azaltarak daha kararlı bir öğrenme süreci sağlamıştır.

- Kalibrasyon model güvenilirliğini artırdı mı?

Sigmoid kalibrasyon, modellerin olasılık çıktılarının daha güvenilir hale getirilmesi amacıyla uygulanmıştır. Brier Score değerlerinin genel olarak düşük seviyede olması, kalibrasyon sonrasında olasılık tahminlerinin makul düzeyde güvenilir olduğunu göstermektedir.

ROC-AUC değerleri modellerin sınıfları genel olarak iyi ayırabildiğini göstermiştir. PR-AUC değerleri özellikle papilödem sınıfının daha az sayıda örnek içermesi nedeniyle önemlidir. Random Forest ve ensemble modellerinin hem ROC-AUC hem de PR-AUC değerlerinin yüksek olması, bu modellerin sınıf ayrımında ve pozitif sınıfı yakalamada güçlü olduğunu göstermektedir.

- Yüksek boyutlu veri yapısı model performansını nasıl etkiledi?

Veri setinde 746 radyomik özellik bulunması, örnek sayısına göre yüksek boyutlu bir yapı oluşturmaktadır. Bu durum aşırı öğrenme riskini artırabilir. Bu nedenle düşük varyanslı özelliklerin silinmesi, korelasyon temelli eleme ve MRMR özellik seçimi gibi boyut azaltıcı adımlar model performansı ve genellenebilirlik açısından kritik öneme sahiptir.

- En önemli 10 radiomics özelliği hangileridir?

Feature importance analizine göre en önemli özellikler Feature\_0005, Feature\_0040, Feature\_0436, Feature\_0224, Feature\_0570, Feature\_0670, Feature\_0592, Feature\_0164, Feature\_0022 ve Feature\_0478 olarak belirlenmiştir.

Final feature importance analizinde en yüksek katkıya sahip özellik Feature\_0005 olmuştur (importance = 0.658023). Bu özelliği Feature\_0040 (0.049211), Feature\_0436 (0.034976), Feature\_0224 (0.031259) ve Feature\_0570 (0.030640) izlemiştir. Feature\_0005'in diğer özelliklere göre belirgin şekilde yüksek önem değerine sahip olması, model kararlarında bu radyomik özelliğin baskın bir rol oynadığını göstermektedir.

**Tablo 2. En önemli 10 radyomik özellik**

| feature      | importance |
|--------------|------------|
| Feature_0005 | 0.6580     |
| Feature_0040 | 0.0492     |
| Feature_0436 | 0.0350     |
| Feature_0224 | 0.0313     |
| Feature_0570 | 0.0306     |
| Feature_0670 | 0.0261     |
| Feature_0592 | 0.0260     |
| Feature_0164 | 0.0236     |
| Feature_0022 | 0.0221     |

| feature      | importance |
|--------------|------------|
| Feature_0478 | 0.0145     |

## 10. Sonuc

Bu calismada veri sızıntısını engelleyen hasta seviyesinde bir makine ogrenmesi pipeline'i kurulmustur. Elde edilen sonuclar, radyomik ozelliklerin papilodem siniflandirmasinda kullanilabilirliğini degerlendirmek icin raporlanmistir.

Final test seti sonuclarına göre en yüksek Macro-F1 skoru KNN modeli ile elde edilmiştir (Macro-F1 = 0.9133). KNN modeli ayrıca en yüksek doğruluk değerini vermiştir (Accuracy = 0.9337). Bu sonuç, KNN modelinin test setindeki genel sınıflandırma performansının diğer modellere göre daha güçlü olduğunu göstermektedir.

ROC-AUC açısından en başarılı model Random Forest olmuştur (ROC-AUC = 0.9809). PR-AUC metriğinde de en yüksek değer Random Forest modeli ile elde edilmiştir (PR-AUC = 0.9583). Bu durum Random Forest modelinin olasılık skorlarını sınıfları ayıracak şekilde güçlü biçimde sıralayabildiğini göstermektedir.

RF, ET ve GB modellerinden oluşturulan soft voting ensemble modeli de güçlü bir performans göstermiştir (Macro-F1 = 0.8896, ROC-AUC = 0.9805, PR-AUC = 0.9569). Ancak ensemble model, Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir. Buna karşın ROC-AUC ve PR-AUC değerleri Random Forest sonucuna oldukça yakın olduğu için ensemble modelin olasılık bazlı ayırt edicilik açısından başarılı olduğu söylenebilir.

Bu çalışmada radyomik özellikler kullanılarak normal ve papilödem sınıflarını ayırmaya yönelik hasta seviyesinde veri sızıntısını önleyen bir makine öğrenmesi pipeline'ı geliştirilmiştir. Veri ön işleme, düşük varyans ve korelasyon temelli özellik eleme, MRMR özellik seçimi, Optuna tabanlı hiperparametre optimizasyonu, sigmoid kalibrasyon ve soft voting ensemble adımları uygulanmıştır.

Final test sonuçlarına göre genel sınıflandırma performansı açısından en başarılı model KNN olmuştur. Random Forest modeli ise ROC-AUC ve PR-AUC metriklerinde en yüksek sonuçları vermiştir. Ensemble model güçlü olasılık bazlı ayırt edicilik göstermesine rağmen Macro-F1 açısından en iyi tekil model olan KNN'yi geçememiştir.

Elde edilen bulgular, radyomik özelliklerin papilödem sınıflandırmasında anlamlı ayırt edici bilgi taşıdığını göstermektedir. Bununla birlikte veri setinin yüksek boyutlu olması nedeniyle özellik seçimi ve hasta seviyesinde doğrulama adımları modelin güvenilirliği açısından kritik öneme sahiptir.

## 11. Kaynakca

- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Akiba, T. et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. Proceedings of the 25th ACM SIGKDD International Conference.
- van Griethuysen, J. J. M. et al. (2017). Computational Radiomics System to Decode the Radiographic Phenotype. Cancer Research, 77(21), e104-e107.
- Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images Are More than Pictures, They Are Data. Radiology, 278(2), 563-577.
- scikit-learn documentation: <https://scikit-learn.org/>
- Optuna documentation: <https://optuna.org/>



## 12. Bonus Calismalar

Bu bolumde odevde bonus olarak belirtilen SHAP, LIME, nested cross-validation, deep learning modeli, feature stability, ensemble optimizasyonu ve threshold optimization calismalarinin uretilen tablo ve gorsel sonuclari sunulmustur.

**Tablo 4. Deep learning MLP model sonucu**

| model | accuracy | macro_f1 | roc_auc | pr_auc | brier_score |
|-------|----------|----------|---------|--------|-------------|
| MLP   | 0.9286   | 0.9095   | 0.9561  | 0.9313 | 0.0660      |

**Tablo 5. SHAP analizinde en etkili ozellikler**

| feature      | mean_abs_shap |
|--------------|---------------|
| Feature_0005 | 2.7414        |
| Feature_0164 | 2.3737        |
| Feature_0436 | 1.5701        |
| Feature_0028 | 0.9571        |
| Feature_0688 | 0.8988        |
| Feature_0670 | 0.7833        |
| Feature_0571 | 0.6436        |
| Feature_0478 | 0.6373        |
| Feature_0022 | 0.6229        |
| Feature_0135 | 0.4871        |

**Tablo 6. LIME lokal aciklama agirliklari**

| model | test_index | feature_rule          | lime_weight |
|-------|------------|-----------------------|-------------|
| GB    | 154.0000   | Feature_0005 > 0.78   | 0.4993      |
| GB    | 154.0000   | Feature_0164 > 0.67   | 0.1662      |
| GB    | 154.0000   | Feature_0043 <= 0.00  | 0.1606      |
| GB    | 154.0000   | Feature_0436 > 0.51   | 0.1352      |
| GB    | 154.0000   | Feature_0022 > 0.53   | 0.1047      |
| GB    | 154.0000   | Feature_0478 > 0.59   | 0.0891      |
| GB    | 154.0000   | Feature_0224 <= -0.57 | 0.0879      |
| GB    | 154.0000   | Feature_0491 <= -0.45 | 0.0536      |
| GB    | 154.0000   | Feature_0034 <= -0.47 | -0.0529     |
| GB    | 154.0000   | Feature_0040 > 0.67   | 0.0402      |

**Tablo 7. Nested cross-validation dis fold sonuclari**

| fold   | selected_model | inner_best_macro_f1 | outer_macro_f1 | outer_roc_auc | outer_pr_auc |
|--------|----------------|---------------------|----------------|---------------|--------------|
| 1.0000 | RF             | 0.9476              | 0.7752         | 0.8075        | 0.7905       |
| 2.0000 | GB             | 0.8653              | 0.8999         | 0.9476        | 0.9408       |
| 3.0000 | MLP            | 0.8370              | 0.8548         | 0.9984        | 0.9965       |

**Tablo 8. Feature stability analizinde en stabil ozellikler**

| feature      | selection_count | n_folds | stability_percent |
|--------------|-----------------|---------|-------------------|
| Feature_0022 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0027 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0040 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0043 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0135 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0166 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0224 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0368 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0408 | 5.0000          | 5.0000  | 100.0000          |
| Feature_0478 | 5.0000          | 5.0000  | 100.0000          |


**Tablo 9. Ensemble agirlik optimizasyonu**

| rf_weight | et_weight | gb_weight | validation_macro_f1 | test_macro_f1 | test_roc_auc | test_pr_auc |
|-----------|-----------|-----------|---------------------|---------------|--------------|-------------|
| 0.1000    | 0.8000    | 0.1000    | 0.8446              | 0.9048        | 0.9749       | 0.9502      |

**Tablo 10. Threshold optimization sonuclari**


| model            | best_threshold | validation_macro_f1 | test_macro_f1 | test_recall | test_precision |
|------------------|----------------|---------------------|---------------|-------------|----------------|
| SVM              | 0.5200         | 0.8601              | 0.9048        | 0.7500      | 1.0000         |
| KNN              | 0.6900         | 0.8661              | 0.9048        | 0.7500      | 1.0000         |
| LR               | 0.5400         | 0.8520              | 0.8973        | 0.7321      | 1.0000         |
| MLP              | 0.8300         | 0.8580              | 0.8896        | 0.7143      | 1.0000         |
| GB               | 0.7000         | 0.8520              | 0.8836        | 0.7143      | 0.9756         |
| ET               | 0.7200         | 0.8661              | 0.8819        | 0.6964      | 1.0000         |
| WeightedEnsemble | 0.7200         | 0.8580              | 0.8819        | 0.6964      | 1.0000         |
| Ensemble         | 0.7500         | 0.8580              | 0.8580        | 0.6429      | 1.0000         |
| RF               | 0.8000         | 0.8580              | 0.8497        | 0.6250      | 1.0000         |

### Sekil 7. SHAP özellik etkisi analizi




Yorum: SHAP analizi, model tahminlerine en fazla katkıda bulunan özellikleri açıklamaktadır. Bu analiz, feature importance sonuçlarıyla birlikte yorumlandığında model kararlarının hangi radyomik değişkenlere dayandığını daha anlaşılır hale getirmektedir.

### Sekil 8. LIME lokal açıklanabilirlik analizi




Yorum: LIME analizi, seçilen tek bir test örneği için model kararını lokal olarak açıklamaktadır. Bu grafik, ilgili örnekte hangi özellik aralıklarının papilodem veya normal sınıf tahminini desteklediğini göstererek model yorumlanabilirliğini artırmaktadır.

### Sekil 9. Nested cross-validation sonuclari




Yorum: Nested cross-validation sonuclari, model secimi ve performans tahmininin daha tarafsiz degerlendirilmesini saglamaktadir. Dis fold sonuclarinin birlikte raporlanmasi, model performansinin farkli hasta gruplari üzerindeki kararliligini incelemeye yardim eder.

### Sekil 10. Feature stability analizi




Yorum: Feature stability analizi, farkli cross-validation foldlarinda secilen ozelliklerin ne kadar tutarli oldugunu gostermektedir. Yuksek stabiliteye sahip ozellikler, modelin yalnızca tek bir bolunmeye bagli olmayan daha guvenilir sinyaller kullandigini destekler.

**Sekil 11. Ensemble agirlik optimizasyonu**



Yorum: Ensemble optimizasyonu, RF, ET ve GB modellerinin soft voting yapısındaki ağırlıklarını validation performansına göre ayarlamaktadır. Bu yaklaşım, ensemble modelin tüm üyeleri eşit kabul etmek yerine daha etkili modellerden daha fazla yararlanmasını sağlamaktadır.

**Sekil 12. Threshold optimization sonuclari**



Yorum: Threshold optimization analizi, varsayılan 0.50 karar esigi yerine validation setinde daha uygun esiklerin denenmesini sağlamaktadır. Bu işlem, precision ve recall arasındaki dengeyi klinik önceliklere göre ayarlamak için kullanılabilir.